第 1 周周报

一、本周工作

1. 行业技术调研

- 浏览了智能体与多模态大模型方向的多篇技术博客和行业文章，建立整体认知
- 精读 Ui-TARS 论文，并对照其开源实现理解具体设计
- 研读 Claude Computer Use 官方技术文档，梳理其交互流程
- 精读 ScreenAgent 论文与对应 GitHub 仓库
- 从感知、规划、执行、反馈四个维度，对比上述Ui-TARS和ScreenAgent技术路线的架构差异

2. 开发环境搭建

- 基于 conda 创建 Python 3.10 虚拟环境 gui_agent
- 安装 PyTorch 2.2.1（cu121）
- 完成 CUDA 与显卡驱动配置，确认 GPU 可用
- 安装 GUI 操作与 OCR 相关依赖：PyAutoGUI、mss、OpenCV、EasyOCR
- 安装大模型与智能体框架：LangChain、Transformers 等
- 完成 Git 配置并初始化 GitHub 项目仓库
- 编写功能测试脚本，验证各基础库可正常导入与运行

二、本周产出

- 《ScreenAgent 与 UI-TARS 技术对比报告》：涵盖 Ui-TARS、ScreenAgent 两条技术路线的架构对比
- 《开发环境配置文档》：包含主机信息、GPU 与 CUDA 版本、conda 安装、依赖清单、配置步骤、验证方法
- GitHub 仓库：https://github.com/dhebhxh/gui-agent
- 导入测试脚本：`test_imports.py`
- 功能测试脚本：`test_functions.py`

三、遇到的问题与解决

显存不足问题

问题：主流多模态大模型推理/微调推荐显存 8 GB 以上，本地电脑仅 6 GB，无法满足模型加载需求

解决：

训练阶段：采用 AutoDL 平台租用云端 GPU 进行训练，规避本地显存限制
推理阶段：采用远程推理方案，本地只负责屏幕截图，通过实时传输将图像发送至远程服务器完成推理，再回传动作指令

四、下周计划

第 2 周：桌面感知与控制核心模块开发

模块	任务
屏幕截图模块	使用 PyAutoGUI / mss 实现跨平台实时截图；支持多分辨率、多显示器适配；实现定时截图与手动截图；保存截图并验证图像质量
OCR 与 UI 元素识别	对截图进行文字识别；使用 OpenCV 做 UI 元素检测与边界框绘制；输出文字内容 + 坐标 + 置信度
鼠标键盘控制模块	实现鼠标点击（左键、右键、双击）、拖拽、键盘输入、滚动、组合键与快捷键
测试	编写单元测试

下周交付物：桌面感知与控制模块完整代码 + 单元测试报告 + 第二周周报