第 2 周周报

一、本周工作

1. 感知与控制模块 代码与测试
2. 屏幕元素检测与提取模块 代码与测试

二、本周产出

1 感知与控制模块

1.1 代码位置

1. `src/dispatcher.py`
2. `src/test_dispatcher.py`

1.2 模块介绍

`ActionDispatcher` 是基于动作字典的命令分发器，把抽象动作描述转为具体鼠标/键盘/截屏操作，是框架的**执行层**。

- **核心方法**：`dispatch(action)`，按 `action["type"]` 调用 `_do_<type>`，新增动作只需加方法。
- **输入**：`{"type": "...", 其他参数...}`
- **输出**：`{"type": "ok"}` / `{"type": "image", "data": ...}` / `{"type": "text", "data": ...}`

支持 19 种动作：截图、光标位置、鼠标移动/点击（左中右）/双击/拖拽/按下抬起/滚动、按键（单键/组合键/按下/抬起）、文本输入。

action type	输入字段	必填字段	可选字段	输出
`screenshot`	—	—	—	`{"type": "image", "data": <PNG bytes>}`
`cursor_position`	—	—	—	`{"type": "text", "data": "[x, y]"}`
`mouse_move`	`x`, `y`	`x`, `y`	—	`{"type": "ok"}`
`left_click`	`x`, `y`, `modifiers`	—	`x`, `y`, `modifiers`	`{"type": "ok"}`
`right_click`	`x`, `y`, `modifiers`	—	`x`, `y`, `modifiers`	`{"type": "ok"}`
`middle_click`	`x`, `y`, `modifiers`	—	`x`, `y`, `modifiers`	`{"type": "ok"}`

action type	输入字段	必填字段	可选字段	输出
left_double_click	x, y, modifiers	—	x, y, modifiers	{"type": "ok"}
left_click_drag	start_x, start_y, end_x, end_y, modifiers	start_x, start_y, end_x, end_y	modifiers	{"type": "ok"}
left_mouse_down	—	—	—	{"type": "ok"}
left_mouse_up	—	—	—	{"type": "ok"}
right_mouse_down	—	—	—	{"type": "ok"}
right_mouse_up	—	—	—	{"type": "ok"}
middle_mouse_down	—	—	—	{"type": "ok"}
middle_mouse_up	—	—	—	{"type": "ok"}
scroll	direction, amount, x, y	direction	amount, x, y	{"type": "ok"}
key_press	key	key	—	{"type": "ok"}
key_down	key	key	—	{"type": "ok"}
key_up	key	key	—	{"type": "ok"}
type_text	text	text	—	{"type": "ok"}

1.3 单元测试

- 文件 test_dispatcher.py，框架 unittest + Mock，共 **7 个测试类、38 个用例**。
- 覆盖全部 19 种动作，Mock 隔离 pyautogui/mss。

2 屏幕元素检测与提取模块

2.1 代码位置

1. src/screen_element_extractor.py
2. src/test_extractor.py

2.2 模块介绍

ScreenElementExtractor 是屏幕截图结构化解析器：输入一张截图，输出带类型、坐标、文本的 UI 元素列表 + 可视化验证图。

- **核心方法**：process(image_path, ...) → (结构化结果字典, 验证图)
- **流程**：EasyOCR 识别文字 → OpenCV 检测图形 → IoU 去重融合 → 推断类型 → 绘制验证图
- **验证图配色**：button、text、input、icon

2.3 功能验证

输入：`documents/image/screenshot.png`

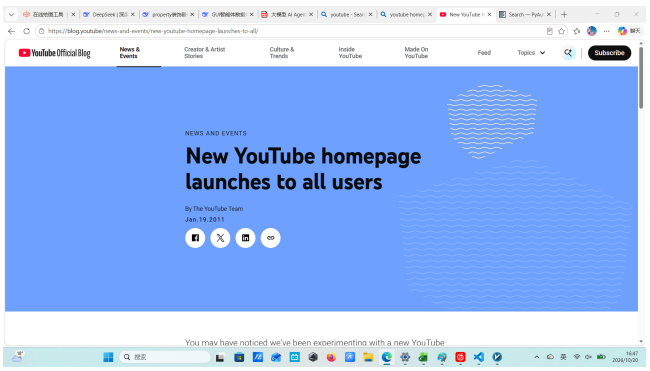
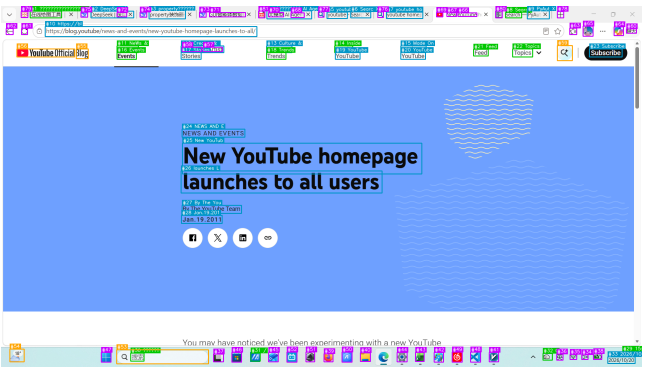
结果：`documents/image/output_annotated.png`, `documents/output_elements.json`

类型	数量
button	11
text	20
input	6
icon	44

输出 JSON 片段：


```
{
  "screenshot_size": [1920, 1080],
  "element_count": 81,
  "elements": [
    {
      "bbox": [87, 15, 181, 35],
      "text": "在线绘图工具",
      "confidence": 0.5561,
      "source": "ocr",
      "element_id": 1,
      "type": "button",
      "center": [134, 25]
    }
  ]
}
```


原图 vs 验证图：

原图	验证图
	

文字识别准确（如 "2026/10/20" 置信度 0.9991）；纯图标由轮廓通道补充检出，弥补 OCR 短板；搜索框/地址栏正确推断为 input；OCR 与轮廓按 IoU 去重，无重复框选。

三、遇到的问题与解决

问题：无文字图标提取困难。

解决：配合多模态大模型识别，弥补 OpenCV 轮廓检测对纯图形语义理解的不足。

四、下周计划

第 3 周：公开 GUI 数据集处理与基础 Agent 框架搭建

模块	任务
公开 GUI 数据集处理	下载 ScreenAgent 数据集；下载 WebArena 数据集；下载 Mind2Web 数据集；统一数据格式（指令、截图、动作、坐标）；清洗无效样本；划分训练集/验证集；编写数据集预处理脚本
基础 Agent 框架搭建	基于 LangChain 搭建 Agent 骨架；基于 LlamaIndex 搭建检索或工具调用能力；定义 Agent 的输入输出接口；实现简单任务拆解与规划；实现任务步骤序列生成
大模型调用接口	支持 API 调用方式；支持开源多模态模型本地部署；接入 Qwen-VL、GLM-4V、Llama 3.2 Vision；实现模型切换与配置管理；测试模型对截图的理解能力

下周交付物：数据集预处理脚本 + 基础 Agent 框架代码 + 模型调用接口文档 + 第三周周报